# Tema 4 Síntese

## Geração de código

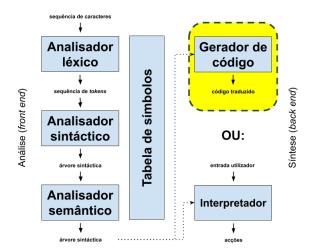
Compiladores, 2º semestre 2023-2024

Miguel Oliveira e Silva, Artur Pereira, DETI, Universidade de Aveiro

### Conteúdo

1	Síntese: geração de código		
	1.1	Geração de código máquina	2
	1.2	Geração de código	3
2	Strin	ng Template	3
	2.1	Geração de código: padrões comuns	6
		Geração de código para expressões	
3		ese: geração de código intermédio	7
	3.1	Código de triplo endereço	7
	3.2	TAC: Exemplo de expressões binárias	7
	3.3	TAC: Endereços e instruções	
	3.4	Controlo de fluxo	
		Funções	

## Síntese: geração de código



• Podemos definir o objectivo de um compilador como sendo traduzir o código fonte de uma linguagem para outra linguagem.

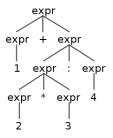
```
source language --- Compiler --- target language
```

- A geração do código para a linguagem destino pode ser feita por diferentes fases (podendo incluir fases de optimização), mas nós iremos abordar apenas uma única fase.
- A estratégia geral consiste em identificar padrões de geração de código, e após a análise semântica percorrer novamente a árvore sintáctica (mas já com a garantia muito importante de inexistência de erros sintácticos e semânticos) gerando o código destino nos pontos apropriados.

#### Exemplo: Calculadora

· Código fonte:

```
1+2*3:4
```



• Uma possível compilação para Java:

```
public class CodeGen {
   public static void main(String[] args) {
      int v2 = 1;
      int v5 = 2;
      int v6 = 3;
      int v4 = v5 * v6;
      int v7 = 4;
      int v3 = v4 / v7;
      int v1 = v2 + v3;
      System.out.println(v1);
```

#### Geração de código máquina

• Tradicionalmente, o ensino de processadores de linguagens tende a dar primazia à geração de código baixo nível (linguagem máquina, ou assembly).

- A larga maioria da bibliografia mantém esse enfoque.
- No entanto, do ponto de vista prático serão poucos os programadores que, fazendo uso de ferramentas para gerar processadores de linguagens, necessitam ou ambicionam este tipo de geração de código.
- Nesta disciplina vamos, alternativamente, discutir a geração de código numa perspectiva mais abrangente, incluindo a geração de código em linguagens de alto nível.
- No que diz respeito à geração de código em linguagens de baixo nível, é necessário um conhecimento robusto em arquitectura de computadores e lidar com os seguintes aspectos:
  - Representação e formato da informação (formato para números inteiros, reais, estruturas, array, etc.);
  - Gestão e endereçamento de memória;
  - Implementação de funções (passagem de argumentos e resultado, suporte para recursividade com pilha de chamadas e *frame pointers*);
  - Alocação de registos do processador.
- (Consultar a bibliografia recomendada para estudar este tipo de geração de código.)

#### 1.2 Geração de código

- Seja qual for o nível da linguagem destino, uma possível estratégia para resolver este problema consiste em identificar sem ambiguidade padrões de geração de código associados a cada elemento gramatical da linguagem.
- Para esse fim, é necessário definir o contexto de geração de código para cada elemento (por exemplo, geração de instruções na linguagem destino, ou atribuir a valor a uma variável), e depois garantir que o mesmo é compatível com todas as utilizações do elemento.



$$\begin{aligned}
\cdots & (e_1) \\
v_1 &= e_1 \\
\cdots & (e_2) \\
v_2 &= e_2 \\
v_+ &= v_1 + v_2
\end{aligned}$$

- Como a larguíssima maioria das linguagens destino são textuais, esses padrões de geração de código consistem em padrões de geração de texto.
- Assim sendo, em Java, poderíamos delegar esse problema no tipo de dados String, StringBuilder, ou mesmo na escrita directa de texto em em ficheiro (ou no *standard output*).
- No entanto, também aí o ambiente ANTLR4 fornece uma ajuda mais estruturada, sistemática e modular para lidar com esse problema.

## 2 String Template

- A biblioteca (Java) *String Template* fornece uma solução estruturada para a geração de código textual.
- O software e documentação podem ser encontrados em http://www.stringtemplate.
- Para ser utilizada é apenas necessário o pacote ST-4.?.jar (a instalação feita do antlr4 já incluiu este pacote).
- Vejamos um exemplo simples:

```
import org.stringtemplate.v4.*;
...
// code gen. pattern definition with <name> hole:
ST hello = new ST("Hello, <name>");
// hole pattern definition:
hello.add("name", "World");
```

```
// code generation (to standard output):
System.out.println(hello.render());
```

- Mesmo sendo um exemplo muito simples, podemos já verificar que a definição do padrão de texto, está separada do preenchimento dos "buracos" (atributos ou expressões) definidos, e da geração do texto final.
- Podemos assim delegar em partes diferentes do gerador de código, a definição dos padrões (que passam a pertencer ao contexto do elemento de código a gerar), o preenchimento dos "buracos" definidos, e a geração do texto final de código.
- Os padrões são blocos de texto e expressões.
- O texto corresponde a código destino literal, e as expressões são em "buracos" que podem ser preenchidos com o texto que se quiser.
- Sintaticamente, as expressões são identificadores delimitados por <expr> (ou por \$).

```
import org.stringtemplate.v4.*;
...
ST assign = new ST("<var> = <expr>;\n");
assign.add("var", "i");
assign.add("expr", "10");
String output = assign.render();
System.out.println(output);
```

#### String Template Group

• Podemos também agrupar os padrões numa espécie de funções (módulo STGroup):

Podemos também colocar cada função num ficheiro:

```
// file assign.st
assign(var, expr) ::= "<var> = <expr>;"
```

```
import org.stringtemplate.v4.*;
...
// assuming that assign.st is in current directory:
STGroup group = new STGroupDir(".");
ST assign = group.getInstanceOf("assign");
assign.add("var", "i");
assign.add("expr", "10");
String output = assign.render();
System.out.println(output);
```

• Uma melhor opção é optar por ficheiros modulares contendo grupos de funções/padrões:

```
// file templates.stg
templateName(arg1, arg2, ..., argN) ::= "single-line template"
templateName(arg1, arg2, ..., argN) ::= <<
multi-line template preserving indentation and newlines
>>
templateName(arg1, arg2, ..., argN) ::= <%
multi-line template that ignores indentation and newlines
%>
```

```
import org.stringtemplate.v4.*;
...
// assuming that templates.stg is in current directory:
STGroup allTemplates = new STGroupFile("templates.stg");
ST st = group.getInstanceOf("templateName");
...
```

#### String Template: dicionários e condicionais

• Neste módulos podemos ainda definir dicionários (arrays associativos).

```
typeValue ::= [
   "integer":"int",
   "real":"double",
   "boolean":"boolean",
   default:"void"
]
```

 Na definição de padrões podemos utilizar uma instrução condicional que só aplica o padrão caso o atributo seja adicionado:

```
stats(stat) ::= <<
if(stat)><stat; separator="\n"><endif>
>>
```

• O campo separator indica que em em cada operação add em stat, se irá utilizar esse separador (no caso, uma mudança de linha).

#### String Template: Funções

Podemos ainda definir padrões utilizando outros padrões (como se fossem funções).

#### String Template: listas

• Também existe a possibilidade de utilizar listas para concatenar texto e argumentos de padrões:

```
binaryExpression(type, var, e1, op, e2) ::=

"<decl(type, var, [e1, \", op, \", e2])>"
```

• ou:

```
binaryExpression(type, var, e1, op, e2) ::= <<
<decl(type, var, [e1, " ", op, " ", e2])>
>>
```

• Para mais informação sobre as possibilidades desta biblioteca devem consultar a documentação existente em: http://www.stringtemplate.org.

#### 2.1 Geração de código: padrões comuns

- Uma geração de código modular requer um contexto uniforme que permita a inclusão de qualquer combinação de código a ser gerado.
- Na sua forma mais simples, o padrão comum pode ser simplesmente uma sequência de instruções.

- Com este padrão, podemos inserir no lugar do "buraco" stat a sequência de instruções que quisermos.
- Naturalmente, que para uma geração de código mais complexa podemos considerar a inclusão de buracos para membros de classe, múltiplas classes, ou mesmo vários ficheiros.
- Para a linguagem C, teríamos o seguinte padrão para um módulo de compilação:

• Se a geração de código for guiada pela árvore sintáctica (como normalmente acontece), então os padrões de código a ser gerados devem ter em conta as definições gramaticais de cada símbolo, permitindo a sua aplicação modular em cada contexto.

#### 2.2 Geração de código para expressões

- Para ilustrar a simplicidade e poder de abstração do *String Template* vamos estudar o problema de geração de código para expressões.
- Para resolver este problema de uma forma modular, podemos utilizar a seguinte estratégia:
  - 1. considerar que qualquer expressão tem a si associada uma variável (na linguagem destino) com o seu valor;
  - 2. para além dessa associação, podemos também associar a cada expressão um ST (stats) com as instruções que atribuem o valor adequado à variável.
- Como habitual, para fazer estas associações podemos definir atributos na gramática, fazer uso do resultados das funções de um *Visitor* ou utilizar a classe ParseTreeProperty
- Desta forma, podemos fácil e de uma forma modular, gerar código para qualquer tipo de expressão.
- Padrões para expressões (para Java) podem ser:

```
typeValue ::= [
   "integer":"int", "real":"double",
   "boolean":"boolean", default:"void"
]
```

```
init(value) ::= "<if(value)> = <value><endif>"
decl(type, var, value) ::=
   "<typeValue.(type)> <var><init(value)>;"

binaryExpression(type, var, el, op, e2) ::=
   "<decl(type, var, [el, \" \", op, \" \", e2])>"
```

• Para C apenas seria necessário mudar o padrão typeValue:

```
typeValue ::= [
    "integer":"int", "real":"double",
    "boolean":"int", default:"void"
]
```

## 3 Síntese: geração de código intermédio

#### 3.1 Código de triplo endereço

- O padrão para expressões é um exemplo duma representação muito utilizada para geração de código baixo nível (em geral, intermédio, e não final), designada por codificação de triplo endereço (TAC).
- Esta designação tem origem nas instruções com a forma: x = y op z
- No entanto, para além desta operação típica de expressões binárias, esta codificação contém outras instruções (ex: operações unárias e de controlo de fluxo).
- No máximo, cada instrução tem três operandos (i.e. três variáveis ou endereços de memória).
- Tipicamente, cada instrução TAC realiza uma operação elementar (e já com alguma proximidade com as linguagens de baixo nível dos sistemas computacionais).

#### 3.2 TAC: Exemplo de expressões binárias

• Por exemplo a expressão a + b \* (c + d) pode ser transformada na sequência TAC:

```
t8 = d;

t7 = c;

t6 = t7+t8;

t5 = t6;

t4 = b;

t3 = t4*t5;

t2 = a;

t1 = t2+t3;
```

• Esta sequência – embora fazendo uso desregrado no número de registos (o que, num compilador gerador de código máquina, é resolvido numa fase posterior de optimização) – é codificável em linguagens de baixo nível.

#### 3.3 TAC: Endereços e instruções

- Nesta codificação, um endereço pode ser:
  - Um nome do código fonte (variável, ou endereço de memória);
  - Uma constante (i.e. um valor literal);
  - Um nome temporário (variável, ou endereço de memória), criado na decomposição TAC.
- As instruções típicas do TAC são:
  - 1. Atribuições de valor de operação binária: x = y op z
  - 2. Atribuições de valor de operação unária:  $x = \mathbf{op} y$
  - 3. Instruções de cópia: x = y
  - 4. Saltos incondicionais e etiquetas: goto L e label L:
  - 5. Saltos condicionais: if x goto L ou ifFalse x goto L

- 6. Saltos condicionais com operador relacional: **if** x **relop** y **goto** L (o operador pode ser de igualdade ou ordem)
- 7. Invocações de procedimentos (param  $x_1 \cdots$  param  $x_n$ ; call p, n; y = call p, n; return y)
- 8. Instruções com arrays (i.e. o operador é os parêntesis rectos, e um dos operandos é o índice inteiro).
- 9. Instruções com ponteiros para memória (como em C)

#### 3.4 Controlo de fluxo

- As instruções de controlo de fluxo são as instruções condicionais e os ciclos.
- Em linguagens de baixo nível muitas vezes estas instruções não existem.
- O que existe em alternativa é a possibilidade de dar "saltos" dentro do código recorrendo a endereços (*labels*) e a instruções de salto (*goto*, ...).

```
      if (cond) {
      A;

      A;
      A

      else {
      goto 12

      label 11:
      B

      label 12:
```

• De forma similar podemos gerar código para ciclos:

```
while (cond) {
    A;
}

label 11:
    ifFalse cond goto 12
    A
    goto 11
    label 12:
```

#### 3.5 Funções

- A geração de código para funções pode ser feita recorrendo a uma estratégia tipo "macro" (i.e. na invocação da funções é colocado o código que implementa a função), ou implementando módulos algorítmicos separados.
- Neste último caso (que, entre outras coisas, permite a recursividade), é necessária a definição de um bloco algorítmico separado, assim como implementar a passagem de argumentos/resultado para/de a função.
- A passagem de argumentos pode seguir diferentes estratégias: passagem por valor, passagem por referência de variáveis, passagem por referência de objectos/registos.
- Para termos implementações recursivas é necessário que se definam novas variáveis em cada invocação da função.
- A estrutura de dados que nos permite fazer isso de uma forma muito eficiente e simples é a pilha de execução.
- Esta pilha armazena os argumentos, variáveis locais à função e o resultado da função (permitindo
  ao código que invoca a função não só passar os argumentos à função como ir buscar o seu resultado).
- Geralmente as arquitecturas de linguagens de baixo nível (CPU's) têm instruções específicas para lidar com esta estrutura de dados.
- Vamos exemplificar esse procedimento: Este código apenas ilustra a ideia. Para uma análise mais detalhada devem consultar a temática de arquitectura de computadores *frame-pointer*.

```
// use:
... f(x,y);
                                                   // use:
                                                   push 0 // result
                                                   push x
// define:
                                                   push y call f,2
int f(int a, int b) {
 Α;
                                                   pop r // result
  return r;
                                                   // define:
                                                   label f:
                                                   pop b
                                                   pop a
                                                   pop r
                                                   store stack-position
                                                   A
// reset stack to stack-position
                                                   restore stack-position
                                                   push r
                                                   return
```